TOMSK POLYTECHNIC UNIVERSITY ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский Томский политехнический университет» (ТПУ)

Школа: **Инженерная школа информационных технологий и робототехники**
Направление подготовки: **09.04.01 Информатика и вычислительная техника**
Отделение школы (НОЦ): **Отделение информационных технологий**

ЛАБОРАТОРНАЯ РАБОТА № 2

по дисциплине

Интеллектуальные системы

Тема задания
Базовый RAG для проверки научных утверждений

Группа	**ФИО**	**Подпись**	**Дата**
8ВМ63	Грязнов Александр Евгеньевич		

Преподаватель

Должность	**ФИО**	**Учёная степень, звание**	**Подпись**	**Дата**
Старший преподаватель	Григорьев Дмитрий Сергеевич			

Томск – 2026 г.

Содержание

Порядок выполнения работы 3
Введение 3
1. Данные и методы 3
2. Результаты экспериментов 4
3. Разбор ошибок и ограничения 5
Заключение 6
Список использованных источников 6

Порядок выполнения работы

Подготовка SciFact и разбиения; построение индекса и проверки; запись прогноза; сборка входов; 420 основных вызовов модели; пересчёт метрик, разбор ошибок и импорт в MLflow.

Введение

Цель — определить, помогает ли поиск научных свидетельств проверять утверждения и где теряется информация [1]. Генерация, дополненная поиском (retrieval-augmented generation, RAG), сначала находит документы, затем передаёт их большой языковой модели (large language model, LLM). Задачи: сравнить LLM-only, RAG и oracle; исследовать k=1, 3, 5 и отделить ошибки поиска, сборки контекста и ответа.

1. Данные и методы

SciFact [2]: 5183 аннотации; из 300 утверждений claims_dev исключено 0. В каждом классе ID упорядочены по SHA-256 строки scifact:<id>; первые 30 образуют dev из 90 примеров. Остальные 210 — holdout для ЛР3, здесь не оценивались. Метки: SUPPORT — есть размеченное обоснование за утверждение; CONTRADICT — против; NOINFO — размеченного обоснования нет. Для прогрева и отладки использованы только claims_train.

Индекс построен на CPU с BAAI/bge-small-en-v1.5 [3], ревизия 5c38ec7. Текст документа — заголовок и аннотация. К запросу добавлена инструкция «Represent this sentence for searching relevant passages: ». Векторы нормированы по L2, поэтому косинусная близость равна скалярному произведению. Матрица 5183×384 float32 занимает 7,59 МиБ. Предел кодировщика 512 токенов обрезал 455 аннотаций (8,78%); это ограничение векторного представления, а не исходных текстов.

Генерация — Kaggle, одна NVIDIA T4, Qwen3-4B-Instruct-2507 [4], ревизия cdbee75, FP16; vLLM 0.33.0, Python 3.13.16, PyTorch 2.14.0+cu132. temperature=0, seed=0, ответ не более 128 токенов. Найденные top-5 сохранены один раз; k=1, 3, 5 — их начала. Контекст собирается по рангу целыми предложениями с исходными номерами до 2048 токенов Qwen вместе с шаблоном диалога; после переполнения сборка останавливается.

JSON Schema задаёт поля label, doc_id, sentences через response_format [5]. Программа дополнительно проверяет ссылки на переданные предложения. Accuracy — доля верных меток после этой проверки; отклонённые ответы остаются в знаменателе. Верная ссылка требует и верной метки, и полного эталонного обоснования. Hit@k показывает наличие релевантного документа, Recall@k — долю найденных релевантных, MRR@k — средний обратный ранг первого из них; поиск оценивается на 60 SUPPORT/CONTRADICT.

Эталон изолирован от поиска и RAG; oracle получает одно полное эталонное обоснование для каждого из 60 SUPPORT/CONTRADICT. Пройдены 13 проверок разбора, 12 тестов оценки и сверка 422 подготовленных входов с токенизатором сервера. Каркас сохраняет манифест, конфигурации, коммиты, отдельные run_id и сырые JSONL. Код и анализ подготовлены с ИИ-помощником; метрики пересчитаны из сохранённых ответов без новых вызовов модели.

2. Результаты экспериментов

Эксперимент 1: LLM-only и RAG k=3 — по 90 вызовов, oracle — 60; всего 240. Ошибок обращения к серверу нет. В таблице 1 приведена основная точность с валидацией; полнота каждого имеющегося класса рассчитана на 30 примерах. Ссылки — на 60 примерах с обоснованием.

Таблица 1 — Качество ответа в эксперименте 1, %

Режим	Верно	Accuracy	SUPPORT	CONTRADICT	NOINFO	Верная ссылка
LLM-only	37/90	41,11	26,67	40,00	56,67	—
RAG k=3	70/90	77,78	83,33	86,67	63,33	65,00
Oracle	26/60	43,33	46,67	40,00	—	40,00

Попарно LLM-only → RAG k=3: исправлено 37, испорчено 4; прирост 36,67 процентного пункта. На одних и тех же 60 примерах: LLM-only — 20/60 (33,33%), RAG k=3 — 51/60 (85,00%), oracle — 26/60 (43,33%). У oracle 26 ответов отклонены из-за непереданных номеров предложений; в 24 случаях набор номеров уменьшен на единицу. Отдельная диагностика только меток даёт 50/60 (83,33%) и не заменяет основную метрику.

Эксперимент 2 добавил по 90 вызовов при k=1 и k=5. В таблице 2 метрики поиска и ссылки рассчитаны на 60 примерах, Accuracy — на 90; в знаменателях не удаляются ошибки.

Таблица 2 — Число документов и качество; MRR безразмерен, остальные доли в %

k	Hit@k	Recall@k	MRR@k	Обоснование передано	Accuracy	Верная ссылка
1	66,67	63,47	0,667	66,67	78,89	53,33
3	85,00	81,44	0,753	85,00	77,78	65,00
5	88,33	85,67	0,760	88,33	74,44	63,33

В среднем передано 1,00 / 2,98 / 4,63 документа и 578 / 1334 / 1853 токена; медиана времени вызова — 1,73 / 2,57 / 3,79 с. Время измерено клиентом для полного HTTP-ответа без заранее выполненного поиска. Попарно от k=3 к k=1 исправлено 6 и испорчено 5; к k=5 — 2 и 5. Сравнение таблицы 2 и рисунка 1 показывает, что рост полноты поиска не гарантирует роста точности ответа.

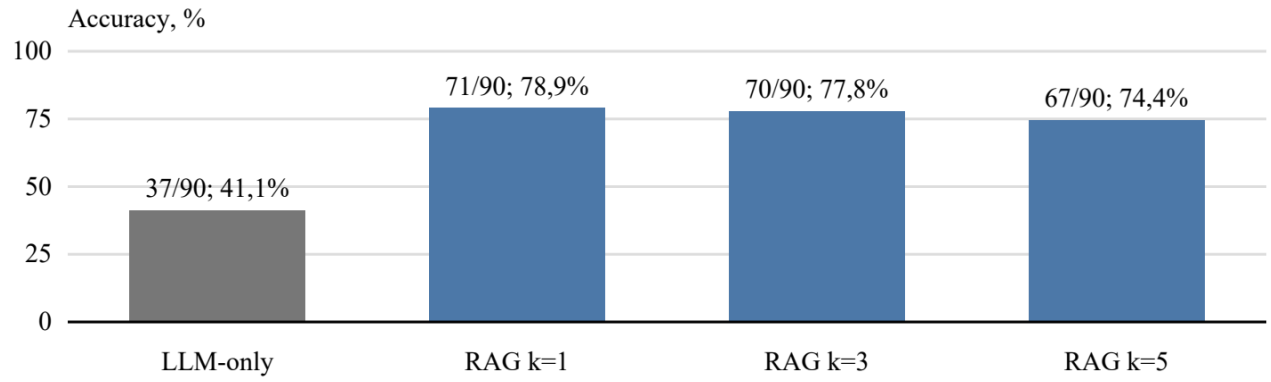


Рисунок 1 — Основная точность на 90 утверждениях с проверкой формата и ссылок

При k=1 общая точность выше k=3 лишь на один ответ; на SUPPORT/CONTRADICT k=3 лучше, но чаще ошибается на NOINFO (11 против 6 ошибок). Рост k до 5 увеличил охват обоснований до 53/60, однако ухудшил ответы. Эти наблюдения не устанавливают статистическую значимость различий.

3. Разбор ошибок и ограничения

Разобраны четыре случая из сохранённых ответов. Для каждого сопоставлены утверждение, найденные документы, переданные предложения и ответ модели. Полная выдача с оценками, тексты предложений и сырые ответы приведены в файле «Разбор_ошибок_ЛР2.md».

1. Свидетельство не найдено, ID 70. Для утверждения «Activation of PPM1D suppresses p53 function» эталонная метка SUPPORT. В первых пяти документах отсутствуют оба эталонных источника: 5956380 и 4414547. Модель ответила NOINFO. Ошибка возникла на этапе поиска.

2. Свидетельство передано, но ответ неверен, ID 183. Эталонная метка — CONTRADICT; предложение 12827098:[3] было передано. Модель указала SUPPORT и предложения [3, 4]. Ссылка допустима по формату, но метка не совпала с эталоном.

3. Ошибка NOINFO, ID 36. Для утверждения о витамине B12 в SciFact нет размеченного обоснования. Модель ответила CONTRADICT и сослалась на документ 33409100:[8]. Отсутствие разметки само по себе не означает ложность утверждения.

4. Ошибка ссылки oracle, ID 56. Передано только предложение 4709641:[1], а модель вернула правильную метку SUPPORT с номерами [0, 1]. Номер [0] не передавался, поэтому ответ отклонён проверкой. JSON Schema задаёт типы полей, но не проверяет принадлежность номера конкретному контексту.

При бюджете 2048 токенов случаев, когда релевантный документ найден, но ни одно полное эталонное обоснование не передано, не обнаружено для k=1, 3 и 5. Вместо такого примера рассмотрена наблюдавшаяся ошибка ссылки oracle.

Прогноз: ожидались 10–20 исправлений и 3–10 ухудшений; получены 37 и 4. Предположение о слабейшем NOINFO у LLM-only не подтвердилось: минимальна полнота SUPPORT (26,67%). Прогноз преимущества k=3 над k=1 не подтвердился на один ответ; oracle также не оказался лучшим даже по отдельной диагностике меток (50 против 51 верного у RAG на общих 60).

Бюджет 1024 вместо 2048 при k=3 снизил долю переданного полного обоснования с 51/60 (85%) до 48/60 (80%); пересобраны те же входы без новых ответов Qwen. Ограничения: один фиксированный dev и одна генерация на условие; метрики привязаны к разметке SciFact; обрезка кодировщиком и ошибки ссылок ограничивают результат.

Заключение

Поиск повысил точность с 41,11% до 77,78% при k=3. Наличие нужного текста не гарантирует верную метку или ссылку; рост полноты поиска также не гарантирует улучшения ответа. Для ЛР3 сохранены исходный индекс, разбиение и неиспользованный holdout; дальнейшие улучшения следует сравнивать при неизменном протоколе оценки.

Список использованных источников

1. Интеллектуальные системы. Лабораторная работа 2. Базовый RAG: поиск свидетельств для проверки научных утверждений // Материалы практикума. URL: https://github.com/dm780009/intsys (дата обращения: 06.11.2026).
2. Wadden D., Lin S., Lo K. [et al.]. Fact or Fiction: Verifying Scientific Claims // Proceedings of EMNLP. 2020. P. 7534–7550. DOI: 10.18653/v1/2020.emnlp-main.609. URL: https://aclanthology.org/2020.emnlp-main.609/ (дата обращения: 06.11.2026).
3. BAAI. BGE-small-en-v1.5: model card // Hugging Face. URL: https://huggingface.co/BAAI/bge-small-en-v1.5 (дата обращения: 06.11.2026).
4. Qwen. Qwen3-4B-Instruct-2507: model card, ревизия cdbee75 // Hugging Face. URL: https://huggingface.co/Qwen/Qwen3-4B-Instruct-2507/blob/cdbee75f17c01a7cc42f958dc650907174af0554/README.md (дата обращения: 06.11.2026).
5. Structured Outputs // vLLM Documentation. Version 0.33.0. URL: https://docs.vllm.ai/en/v0.33.0/features/structured_outputs/ (дата обращения: 06.11.2026).